课程 Project 总览

使用 AI 辅助研究，逐步形成能够被检验的投资策略。

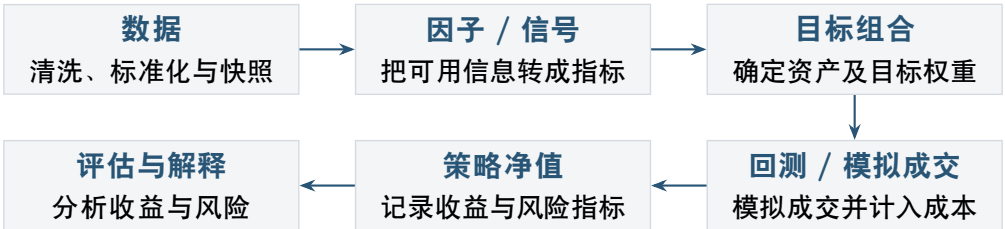
阶段	研究任务	核心问题
P1	**搭建量化投研框架**	**系统能否正确完成一次研究**
P2	复现研报或论文	能否按原方法得到可比较的结果
P3	构造并检验新因子	新想法是否提供增量信息
P4	构建预测或决策模型	模型是否带来样本外改进
P5	形成自己的策略系统	成本与风险约束下，保留哪些设计

Project 1 目标：AI 辅助搭建量化投研框架

建立一个**最小但完整**、**正确**、**可复现**、**可扩展**的研究平台。

目标	说明
完整	从原始数据到策略净值，各模块是如何连接的
正确	数据、因子、收益与成本计算是否符合定义
可复现	相同数据与配置，能否复现主要结果
可扩展	后续 Project 可直接建立在本次 Project 搭建的框架上

框架总览


数据
清洗、标准化与快照
因子 / 信号
把可用信息转成指标
目标组合
确定资产及目标权重
回测 / 模拟成交
模拟成交并计入成本
策略净值
记录收益与风险指标
评估与解释
分析收益与风险

如何搭建一个框架

- **从零写一个框架**：需要提前想好架构
- **使用已有的量化平台**：聚宽、米筐、BigQuant
- **开源代码库**：Backtrader、alphalens、Qlib

数据模块：先确定研究范围，再导入数据

- **研究范围**：明确市场、资产、样本期和日频数据来源。
- **数据快照**：原始数据与清洗结果分别保存，记录下载时间、版本和校验值。
- **复现入口**：提供数据获取说明、导入脚本与配置；不能共享完整数据时提供可分享小样本。

数据字段与质量检查

每条日频记录以 **日期** × **资产代码** 唯一标识，字段含义保持一致。

内容	最低说明
行情与单位	开盘价、收盘价、成交量；注明频率与单位。
价格口径	原始价格与复权信息，或调整后价格的定义与限制。
资产范围	研究的资产名单、筛选条件、覆盖区间与样本数量。

质量报告：重复键、日期顺序、缺失值、非法价格或成交量、覆盖率、清洗前后数量。异常处理需说明原因，缺失值不统一填零。

复权：保持价格序列的口径一致

复权用于处理分红、拆股等公司行动造成的价格尺度变化。

例如一拆二：每股价格由 20 变为 10，持股由 1 股变为 2 股，总价值不变。

$$P_{i,t}^{\mathrm{adj}} = P_{i,t}^{\mathrm{raw}} \frac{a_{i,t}}{a_{i,\tau}}$$

这里采用乘法累计因子约定：P^{raw} 为原始价，a 为复权因子，τ 为固定参考日。

- 计算动量、波动率与收益标签时，明确价格口径，开盘与收盘价保持一致。
- 保存原始价、复权因子、参考日期与数据版本，避免拼接不同参考日期的价格片段。

因子模块：实现三个逻辑有区别的因子

因子是由行情等数据计算的研究指标，用于比较资产或形成信号。

示例	定义示意	研究想法
20 日动量	$C_{i,t}/C_{i,t-20}-1$	近期较强的表现可能持续。
5 日反转	$-(C_{i,t}/C_{i,t-5}-1)$	短期下跌后可能反弹。
20 日低波动	$-\operatorname{std}(r_{i,t-19},\ldots,r_{i,t})$	比较波动较低资产的表现。

因子定义、计算与预处理

- **每个因子一张卡**：名称、研究假设、公式、字段、窗口、预期方向、缺失处理与可能失效情形。
- **统一输出**：`date`，`asset`，`factor`，`value`；通过配置切换因子与参数，公式与回测核心分离。
- **统一方向**：约定“分数越高，预期收益越高”；低波动等指标可取负号，并说明原因。
- **因子预处理**：按需要选择截面排名、中性化、标准化或去极值。

回测模块：配置、运行与交易成本

- **输入**：标准化行情、因子或信号、策略参数与成本参数。
- **配置**：样本区间、调仓频率、持仓数量、费率，以及缺失数据和停牌等情况的处理。
- **输出**：日收益、净值、持仓记录、换手与累计成本；参数改变后可重新运行。

$$\mathrm{Cost}_t = c_b B_t + c_s S_t$$

B_t, S_t 为实际买入、卖出金额；c_b, c_s 为对应费率，按实际成交金额扣费。

回测结果的基本检查

检查	需要核对的内容
输入与配置	资产、样本区间、因子参数、频率与费率与实验说明一致。
收益与净值	净值变化与日收益计算一致，累计收益可独立核对。
交易成本	买卖费用按所设规则计算，未成交部分不扣成交费。
异常与缺失	缺失价格、因子缺失或样本不足时有明确处理与记录。
重复运行	同数据、代码与配置的主要数值结果在声明容差内一致。

因子诊断：IC 与 Rank IC

对固定持有期限 h，在每个形成日 t 的有效资产集合 $S_t^{(h)}$ 上计算：

$$IC_t^{(h)} = \mathrm{Corr}_{i \in S_t^{(h)}} \left(f_{i,t}, y_{i,t}^{(h)} \right)$$

$$RankIC_t^{(h)} = \mathrm{Corr}_{i \in S_t^{(h)}} \left(\mathrm{rank}(f_{i,t}), \mathrm{rank}(y_{i,t}^{(h)}) \right)$$

- **IC**：Pearson 相关，衡量线性关系；**Rank IC**：Spearman 秩相关，衡量排序能力，并列采用平均秩。
- 对每个因子报告覆盖率、分布、有效资产数，以及 IC 的时间序列、均值与标准差；Rank IC 同样报告。
- 事先设最低样本要求；常数或样本不足时记缺失，不改成 0。

先逐日跨资产计算，再沿时间汇总；$IC = 0.05$ 不表示收益为 5%，也不表示预测正确率为 55%。

分组收益：排序差异是否具有经济幅度？

在形成日按因子从低到高分为 K 组，如五分组；第 1 组最低，第 K 组最高。

$$R_{k,t}^{(h)} = \frac{1}{\#G_{k,t}} \sum_{i \in G_{k,t}} y_{i,t}^{(h)}, \qquad \mathrm{Spread}_t^{(h)} = R_{K,t}^{(h)} - R_{1,t}^{(h)}$$

$G_{k,t}$ 是形成时第 k 组的资产集合；上式假定组内标签完整，组内等权。

- 展示各组平均收益与高低组价差，检查单调性与收益差异的大小。
- 预先确定组数、并列值处理与样本不足规则；标签缺失时报告原组人数和有效人数，不重新分组。
- 示例：最高组 1.2%、最低组 0.3%，价差为 0.9 个百分点；它尚未扣费，也不等于可执行多空收益。

多日标签可能重叠，不能直接连续复利为策略净值；分组诊断与策略净值分别展示。

策略绩效：收益、波动率与 Sharpe

以扣费后结果为主。V_t 为策略价值，N 为日收益数，A 为年交易日数；
$R_t = V_t/V_{t-1} - 1$，$e_t = R_t - r_t^f$，r_t^f 为同频率无风险收益。

指标	定义	回答的问题
累计收益	$V_N/V_0 - 1$	整个样本期资金增长多少？
年化收益	$(V_N/V_0)^{A/N} - 1$	复合增长速度换算成年频是多少？
年化波动率	$\sqrt{A}\,\mathrm{std}(R_t)$	日收益波动有多大？
年化 Sharpe	$\sqrt{A}\,\mathrm{mean}(e_t)/\mathrm{std}(e_t)$	单位超额收益波动对应多少回报？

策略绩效：回撤、换手与成本

最大回撤：相对此前高点的最大跌幅。

$$H_t = \max_{0 \le s \le t} V_s, \qquad DD_t = 1 - \frac{V_t}{H_t}, \qquad MDD = \max_t DD_t$$

例：净值 $1 \to 1.2 \to 0.9$，最大回撤为 $1 - 0.9/1.2 = 25\%$。

换手与费用：组合调整带来多少交易负担？

$$\text{Turnover}_t = \frac{B_t + S_t}{V_t^-}, \qquad \text{TotalCost} = \sum_t \text{Cost}_t$$

V_t^- 为交易前总价值；这里采用双边成交额口径，累计成本用货币单位报告。

- 同时观察持仓数量、最大单资产权重与交易次数。
- 对比毛收益与净收益，说明采用同一成交路径归因，还是分别重跑回测。

完成一个小型对照实验，并形成报告

先写问题和预期，再只改变一个主要因素。

例如比较周度与月度调仓，或比较不同因子；其余数据、样本区间和成本口径保持一致。

报告部分	需要呈现的证据
数据与假设	样本、清洗统计、价格与资产池口径、未建模限制。
因子与回测	三个因子的诊断；策略净值、收益、风险与成本指标。
对照与解释	变化来自什么？成本、风险、持仓行为能否解释差异？
复现信息	数据快照、代码版本、配置、运行时间和检查输出。

保留不支持预期的结果，说明局限与下一步。未作适当统计检验时称为描述性结果；重叠标签和反复搜索会影响显著性判断。

自主拓展

方向	可选工作	验收证据
数据工程	增量更新、缓存、动态资产池	增量与全量一致，重复导入不重复。
因子研究工具	因子注册、批量诊断、中性化	新增因子不改回测核心，可批量诊断。
回测真实性	公司行动、部分成交、流动性限制	小情景复核，量化与基础版的差异。
组合与风险	波动率目标、权重限制、风险平价	同信号下比较风险、成本和稳定性。

一个扎实扩展可取得全部扩展分；自拟方向先确认数据可得，并说明它解决了什么具体问题。

基础任务与拓展评价

共同基础 80 分 + 自主拓展 20 分；不设收益、Sharpe 或 IC 达标门槛。

共同基础

- 数据接入、清洗与质量报告。
- 三个因子及相应诊断。
- 可配置回测与绩效分析。
- 对照实验、复现包与研究报告。

拓展评价

- 问题价值。
- 实现并接入系统。
- 验证与对照。
- 解释与局限。

评价关注设计、实现、验证和解释。优先修正计算与复现问题；复杂模型或界面数量本身不加分。

提交材料与演示要求

- **可运行代码**：依赖、README、入口、配置；用架构图和简要文字说明职责、接口与取舍。
- **数据与复现包**：可分享快照或小样本、字典、文件清单、校验值与完整数据获取说明。
- **研究报告**：建议 6–10 页 PDF，说明设计、结果、对照、局限与下一步。